Analisis Kinerja Arsitektur Integrasi Data ETL, ELT, dan Hibrida pada *Data Warehouse* Berbasis *PostgreSQL*

Luthfan Aryananda Purwito (5026221166)

Dosen Penguji 1:

Radityo Prasetianto Wibowo, S.Kom., M.Kom.

Dosen Penguji 2:

Irmasari Hafidz, S.Kom., M.Sc.

Dosen Pembimbing:

Faizal Johan Atletiko, S.Kom., M.T.

Apa saja yang akan dibahas?

BAB 1

Pendahuluan

Apa yang melatarbelakangi tugas akhir ini?

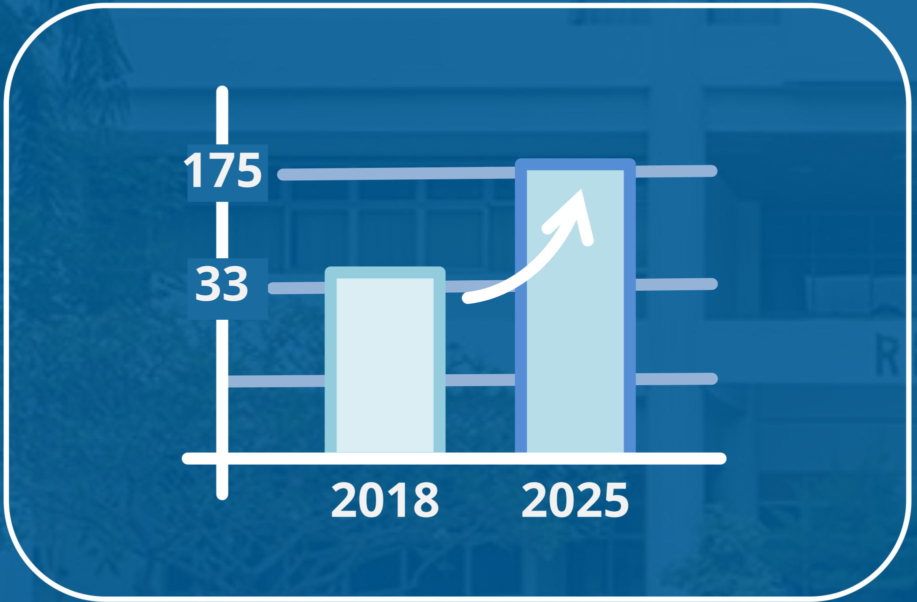

Lonjakan masif pada **volume** dan **varietas** data (terstruktur, semi-terstruktur, dan tidak terstruktur

Reinsel et al. (2018)

Organisasi dituntut memiliki strategi integrasi data yang **efisien** dan **cepat** untuk pengambilan keputusan

Apa yang melatarbelakangi tugas akhir ini?

ETL menghadapi **isu skalabilitas** dan **kinerja** saat menangani data bervolume besar

ELT menawarkan **performa lebih tinggi** dengan memanfaatkan kekuatan komputasi warehouse.

Hibrida menggabungkan **kontrol ETL** dan **kecepatan ELT**.

Apa yang melatarbelakangi tugas akhir ini?

Studi komparatif komprehensif antara ketiga arsitektur ini masih terbatas...

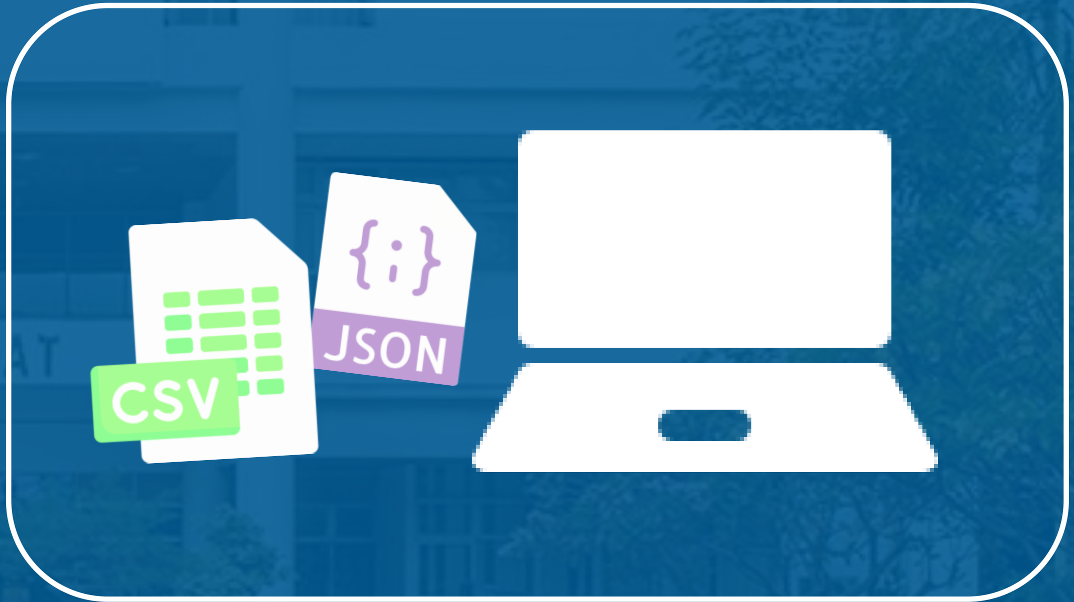

...terutama implementasi skenario *on-premise* dengan variasi format data (CSV, JSON, Parquet)

Rumusan Masalah

01 Bagaimana perbandingan **waktu pemrosesan total** antara arsitektur ETL, ELT, dan hibrida dalam menangani beban kerja dengan bentuk data terstruktur dan semi-terstruktur?

02 Bagaimana perbandingan **efisiensi penggunaan sumber daya (CPU dan memori)** pada ketiga arsitektur tersebut selama proses integrasi data berlangsung?

03 Bagaimana perbandingan **efisiensi penggunaan ruang penyimpanan disk** pada ketiga arsitektur tersebut pada tahap penyimpanan data mentah dan setelah dimuat ke data warehouse?

Tujuan

01 Untuk membandingkan **waktu pemrosesan total** antara arsitektur ETL, ELT, dan hibrida dalam menangani beban kerja dengan bentuk data terstruktur dan semi-terstruktur

02 Untuk membandingkan **efisiensi penggunaan sumber daya (CPU dan memori)** pada ketiga arsitektur tersebut selama proses integrasi data berlangsung

03 Untuk membandingkan **efisiensi penggunaan ruang penyimpanan disk** pada ketiga arsitektur tersebut pada tahap penyimpanan data mentah dan setelah dimuat ke data warehouse

Batasan Masalah

01 **Dataset TPC-H** yang dikonversi menjadi dua jenis:

- Terstruktur (CSV, Parquet)
- Semi-Terstruktur (JSON)

02 **Metrik Pengujian**:

- Waktu pemrosesan total
- Penggunaan CPU
- Penggunaan memori
- Penggunaan ruang penyimpanan

03 **Platform dan teknologi**:

- Data Warehouse: PostgreSQL
- Arsitektur ETL: Python
- Arsitektur ELT: Python + dbt
- Arsitektur Hibrida:
  - Extract, Clean, dan Load dengan Python
  - Transform dengan dbt

Manfaat

01

Praktis

Memberikan **rekomendasi teknis** berbasis data dalam memilih arsitektur integrasi data yang paling optimal, berdasarkan karakteristik data dan kebutuhan spesifik mereka.

02

Akademis

Menyajikan **wawasan dan data perbandingan kuantitatif** antara arsitektur ETL, ELT, dan hibrida yang dapat mengisi kesenjangan riset di bidang integrasi data berskala besar.

BAB 2

Tinjauan Pustaka

Penelitian Terdahulu

A Model for Enhancing Unstructured Big Data Warehouse Execution Time

Marwa Salah Farhan, Amira Youssef and Laila Abdelhamid

A Model for Enchancing Unstructured Big Data Warehouse Execution Time

Marwa Salah Farhan, Amira Youssef, Laila Abdelhamid

- Perbandingan kinerja **kuantitatif** antara ETL, ELT, dan beberapa jenis hibrida.
- Dilakukan secara ***on-premise***
- Metrik yang digunakan:
  - **Waktu eksekusi**
  - **Penggunaan memori**

(2024)

Journal of Computational Intelligence and Robotics

ETL vs. ELT: Optimizing Data Integration for Retail and Insurance Analytics

Venkatesha Prabhu Rambabu, Chandrashekar Althati, Amsa Selvaraj

ETL vs. ELT: Optimizing Data Integration for Retail and Insurance Analytics

Venkatesha Prabhu Rambabu, Chandrashekar Althati, Amsa Selvaraj

- Perbandingan **ETL** dan **ELT**
- Metrik yang digunakan:
  - **Kinerja**
  - Skalabilitas
  - **Efisiensi sumber daya**

(2023)

Penelitian Terdahulu


2020 International Conference on Informatics, Multimedia, Cyber and Information System (ICIMCIS)

Comparison of the E-LT vs ETL Method in Data Warehouse Implementation: A Qualitative Study

[*Comparison of the E-LT vs ETL Method in Data Warehouse Implementation: A Qualitative Study*]()

Haryono et al.

- Perbandingan **kualitatif** antara **ETL** dan **ELT**
- Metrik yang digunakan: **Kinerja**, **dukungan data tidak terstruktur**, **kompleksitas**, dan **biaya**

(2020)

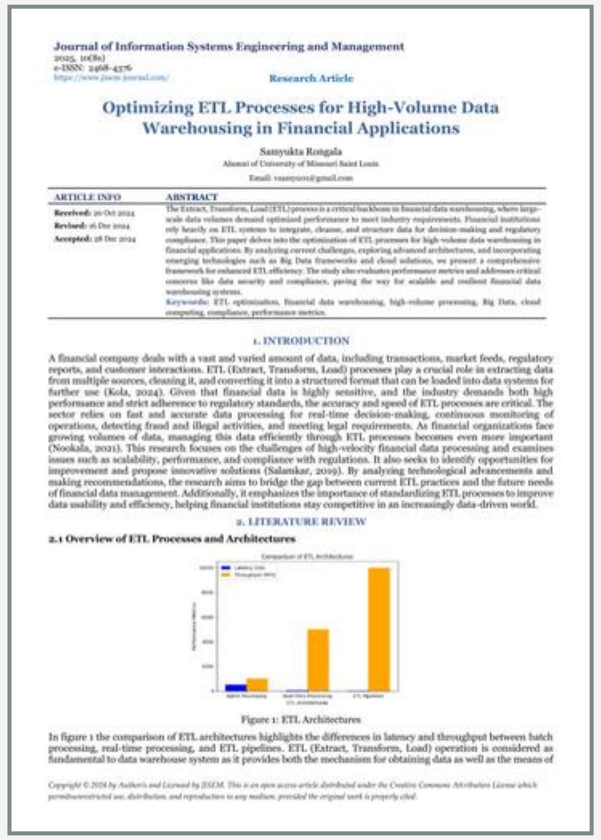
Journal of Information Systems Engineering and Management

Research Article

Optimizing ETL Processes for High-Volume Data Warehousing in Financial Applications

Samyukta Rongala

[*Optimizing ETL Processes for High-Volume Data Warehousing in Financial Applications*]()

Samyukta Rongala

- Evaluasi dan optimalisasi kinerja **ETL**
- Metrik yang digunakan:
  - **Kinerja secara kuantitatif**
- Menyajikan bukti visual kinerja ETL

(2025)

Penelitian Terdahulu

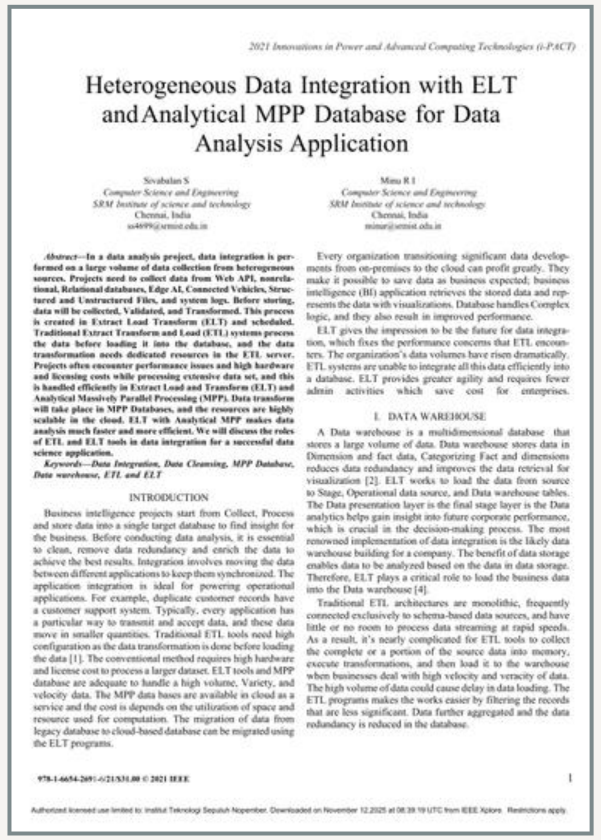

Heterogeneous Data Integration with ELT and Analytical MPP Database for Data Analysis Application

Sivabalan S., Minu R. I.

- **Perbandingan kinerja** ETL dan ELT
- Mengidentifikasi **biaya** perangkat
- Mengidentifikasi **penyebab bottleneck ETL**

(2021)

Perbandingan Performa Teknologi *Data Lake* dan *Data Warehouse* dalam Pengelolaan Data *Stack Overflow* Menggunakan Arsitektur *Hybrid Hub-and-Spoke* dan *Kimball Method*

Ihsan Kamil Al Ghozi

- **Menggunakan ETL** untuk integrasi data
- Metrik yang digunakan: **Durasi proses ETL**, **Efisiensi sumber daya**
- Dilakukan secara **lokal** (*on-premise*)

(2025)

Dasar Teori

5V

1. ***Volume*** : Jumlah data yang sangat besar
2. ***Variety*** : Keragaman tipe dan sumber data, mulai dari data terstruktur hingga data tidak terstruktur
3. ***Velocity*** : Kecepatan akuisisi dan pemrosesan data
4. ***Veracity*** : Kualitas, keakuratan, dan keandalan data
5. ***Value*** : Potensi nilai atau wawasan dan pengetahuan yang bisa diambil untuk pengambilan keputusan

Data Lake

Repositori yang dapat menyimpan **data mentah** dengan **volume yang besar**, dan dibantu oleh deskripsi metadata yang lengkap.

Data yang dapat disimpan:

- Terstruktur
- Semi-terstruktur
- Tidak terstruktur

Risiko:

Dapat menjadi *Data Swamp* jika tidak dikelola dengan baik.

Data Warehouse

Repositori yang dirancang untuk menyimpan data yang bersifat **nonvolatil**, **terintegrasi**, **bervariasi secara waktu**, dan **berorientasi subjek.** (Harby & Zulkernine, 2025)

Data warehouse mengikuti prinsip **OLAP** (*Online Analytical Processing*)

- Tabel fakta
- Tabel dimensi

Dasar Teori

Extract, Transform, Load (ETL)

Proses integrasi data yang memindahkan dan menyiapkan data untuk kebutuhan analisis

Extract
Memasukkan data ke sistem ETL, untuk kebutuhan manipulasi data.

Transform
Biasanya mencakup pembersihan, penggabungan, agregasi, dan sejenisnya.

Load
Pemuatan data ke dalam model dimensional di *data warehouse*.

Extract, Load, Transform (ELT)

Proses integrasi data di mana data mentah **langsung dimuat ke sistem target**

Extract
Mengekstraksi data dari sistem sumber aslinya secara efisien.

Load
Pemuatan data mentah langsung ke *data warehouse* tujuan.

Transform
Pemfilteran, penggabungan, agregasi, dan transformasi analitis lainnya.

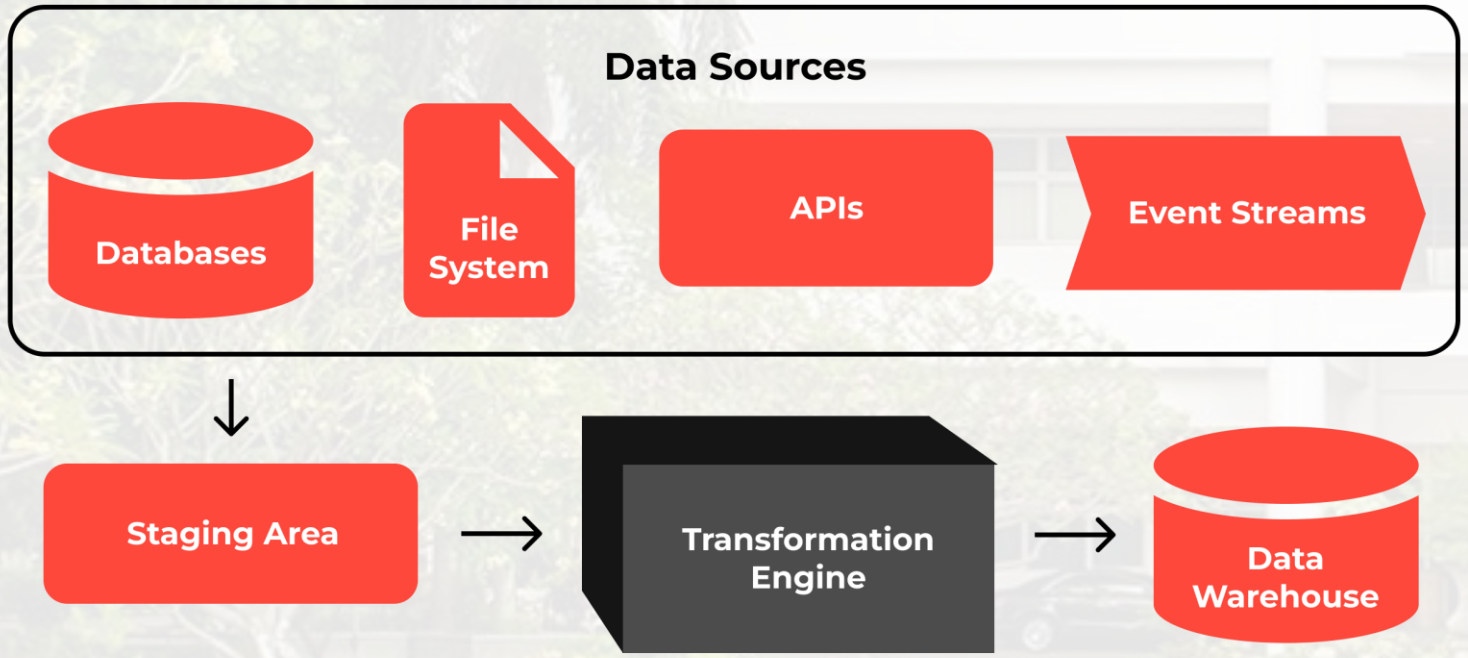

(DataForge, 2023)

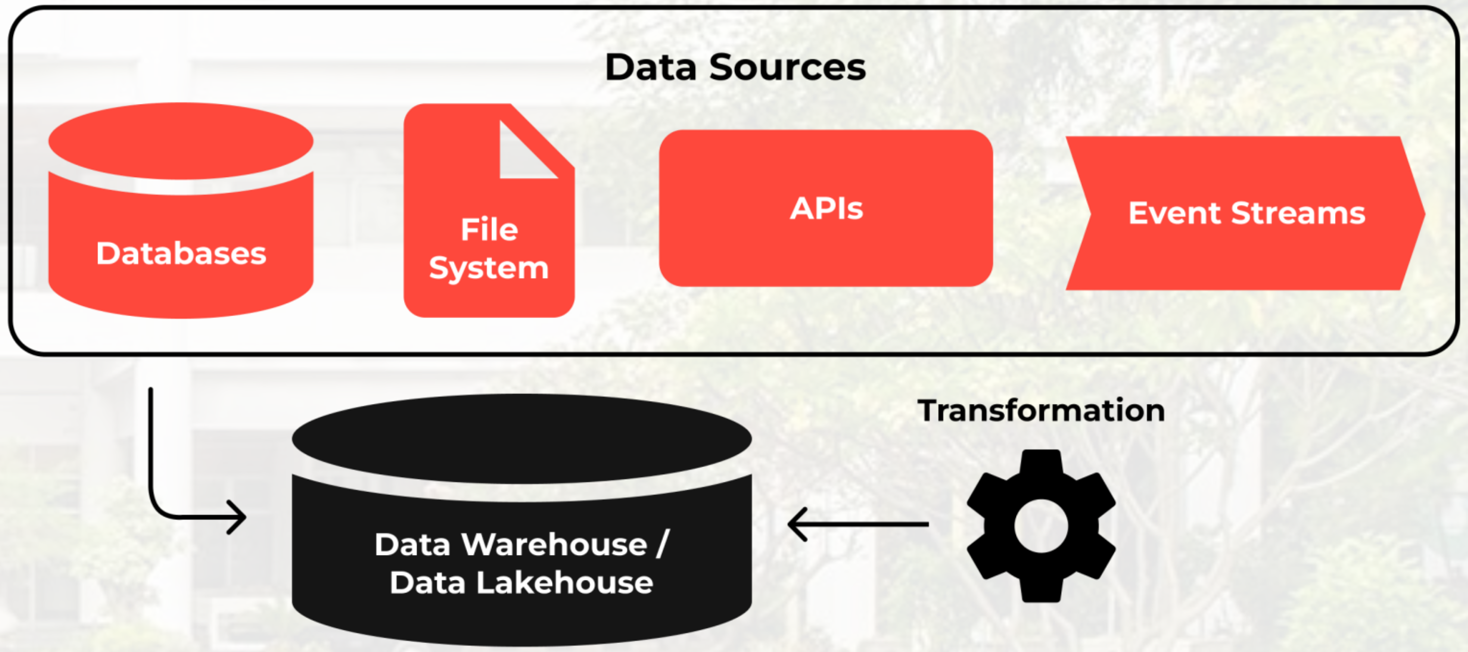

(DataForge, 2023)

Dasar Teori

Arsitektur Hibrida

Proses integrasi data yang memanfaatkan kekuatan kedua model ETL & ELT.

ETL

- Tata kelola
- Kepatuhan
- Kemampuan untuk transformasi data secara kompleks

ELT

- Semi-terstruktur dan tidak terstruktur
- Bervolume besar
- Mampu menangani real-time

***ECLT* (Farhan et al., 2024):**

Menerapkan **transformasi ringan** (seperti pembersihan data) **sebelum data dimuat** ke dalam sistem target

Memanfaatkan kekuatan *engine* sistem tujuan untuk **transformasi yang lebih berat** (seperti agregasi, penggabungan)

Extract → **Clean** → **Load** → **Transform**

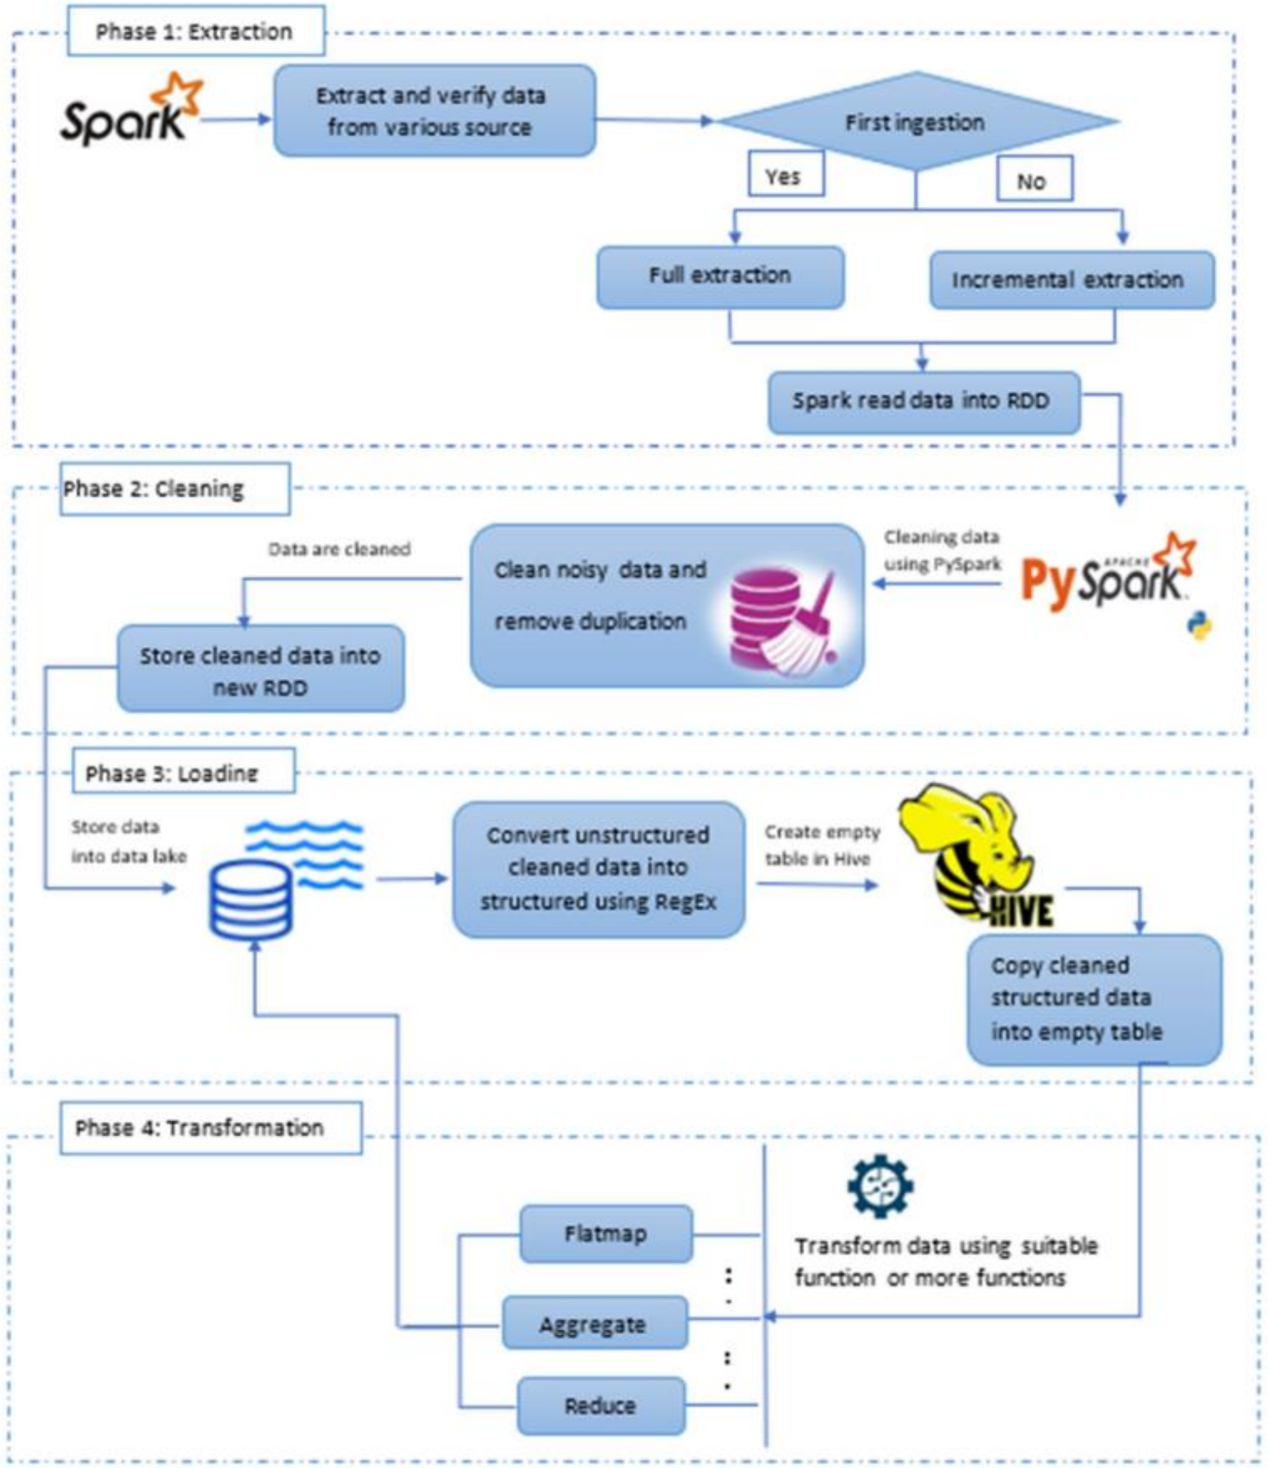

(Farhan et al., 2024)

Dasar Teori

Alat Integrasi Data

PostgreSQL	dbt	Python

Format Penyimpanan Data

CSV	JSON	Apache Parquet

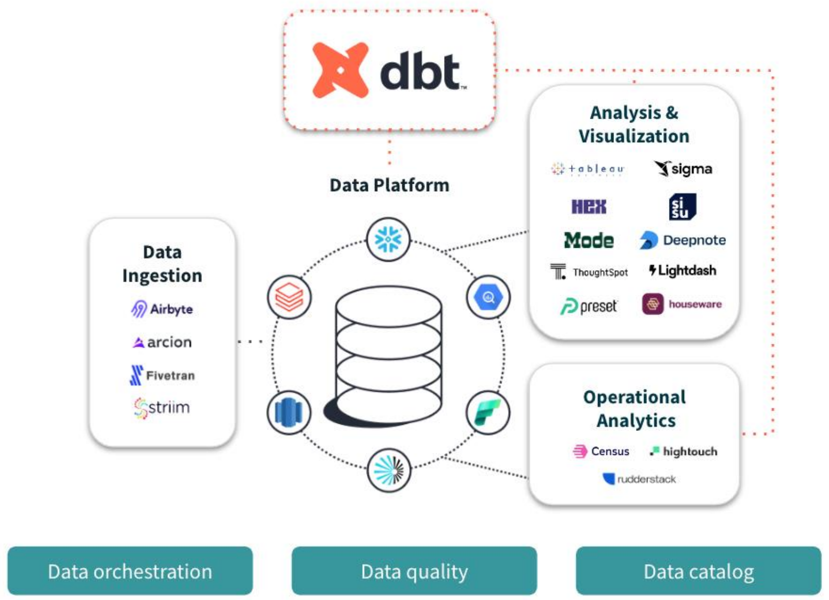

(dbt Labs, n.d.)

dbt (Data Build Tool)

Alat *open-source* modern yang secara khusus dirancang untuk membantu analis data melakukan transformasi data, terutama dalam penerapan metode ELT (extract, load, transform).

Apache Parquet

Format penyimpanan **kolumnar** yang dirancang khusus untuk menyimpan, mengelola, dan menganalisis data bervolume besar secara efisien.

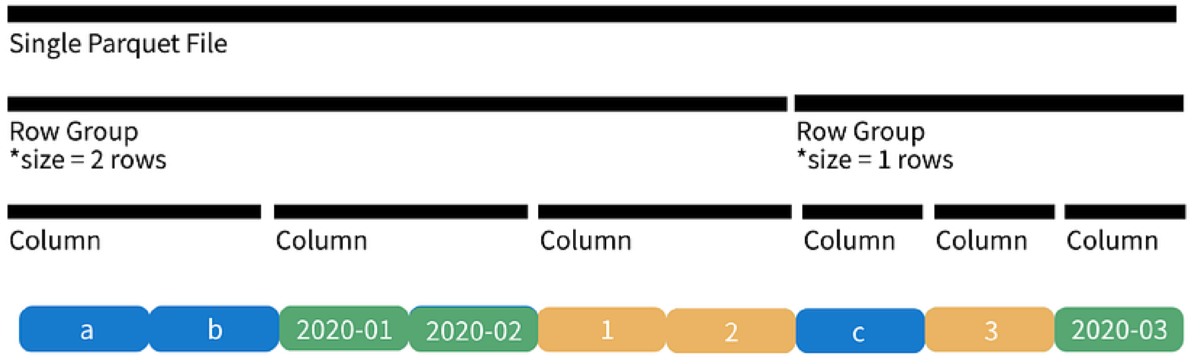

Dasar Teori

TPC-H (TPC Benchmark™ H)

- Merupakan salah satu **benchmark standar industri** yang dikembangkan oleh Transaction Processing Performance Council (TPC).
- Dirancang khusus **untuk mengukur kinerja sistem basis data** terutama dalam menangani tantangan di lingkungan sistem pendukung keputusan modern.
- TPC memiliki **program generator data resmi** yang dinamakan sebagai **DBGEN**.
- Pembuatan volume data dikontrol dengan parameter yang disebut dengan **Scale Factor (SF)**.

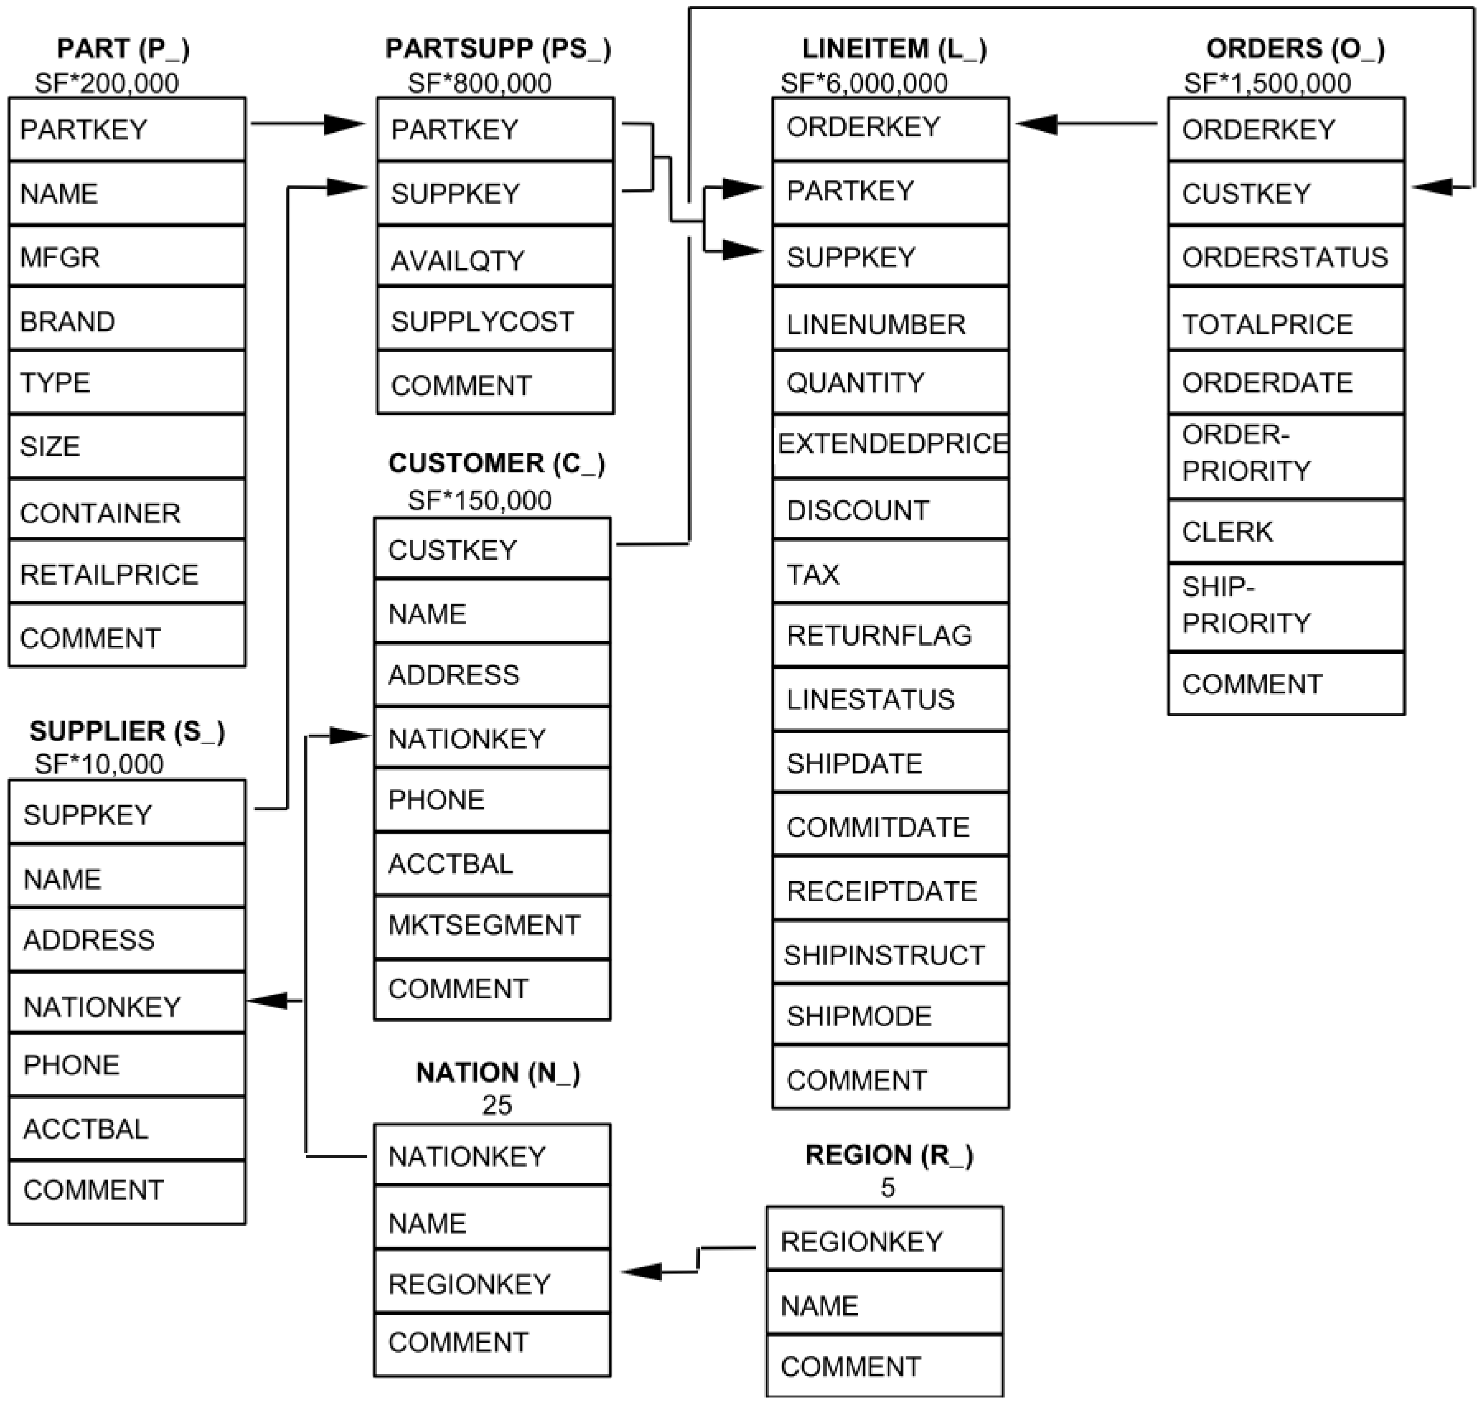

BAB 3

Metodologi

Metodologi Pelaksanaan

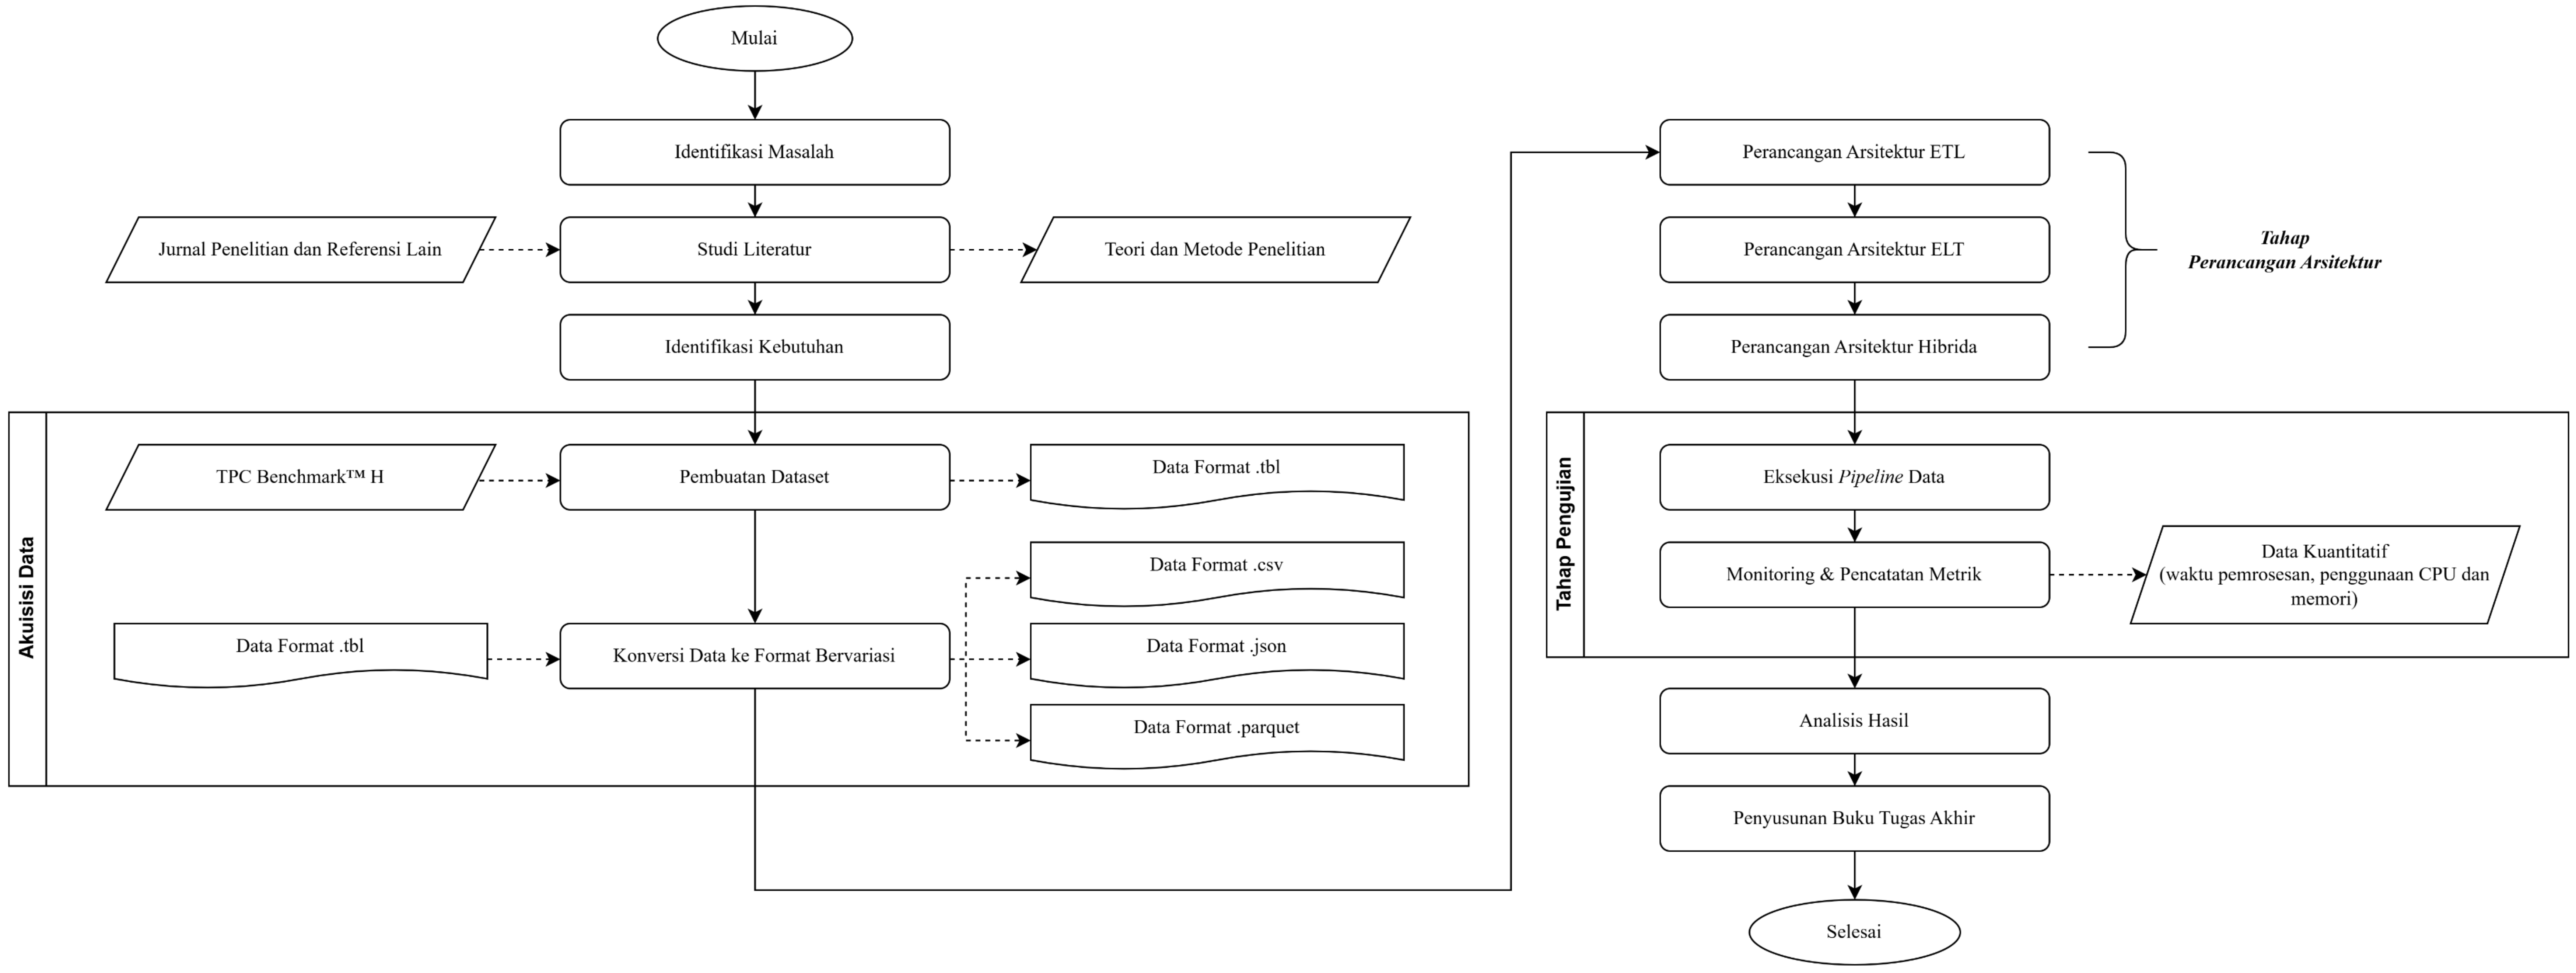

Arsitektur ETL

1 *Extract*

Server

- **Membaca data** sumber TPC-H yang sudah dikonversi menjadi format CSV, JSON, dan Parquet
- Ekstraksi dilakukan menggunakan Python secara bertahap (*chunking*)

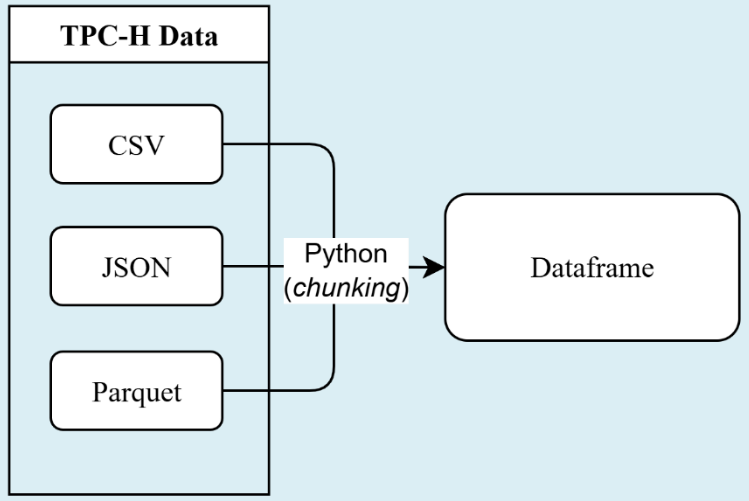

2 *Transform*

Melakukan **seluruh transformasi**, seperti:

- Pembersihan data (penanganan duplikat, *null*)
- Penyesuaian tipe data
- Penggabungan (*JOIN*)
- Agregasi
- Pemfilteran

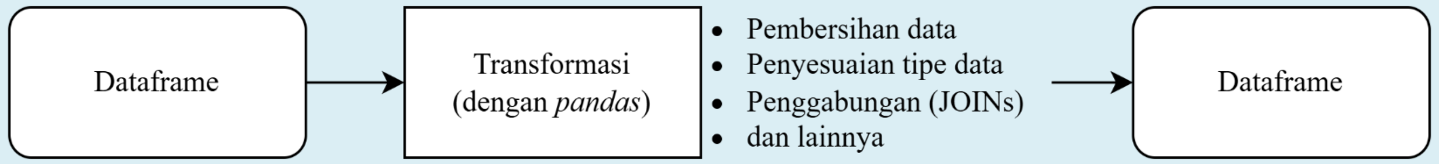

3 *Load*

Database

Tahap **pemuatan data** ke dalam sistem basis data PostgreSQL target

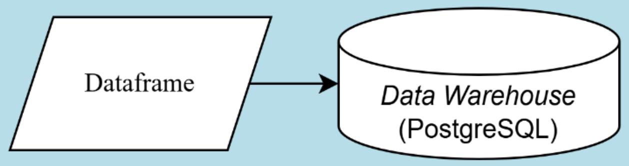

Arsitektur ELT

1

Extract

Server

- **Membaca data** sumber TPC-H yang sudah dikonversi menjadi format CSV, JSON, dan Parquet
- Ekstraksi dilakukan menggunakan Python secara bertahap (*chunking*)

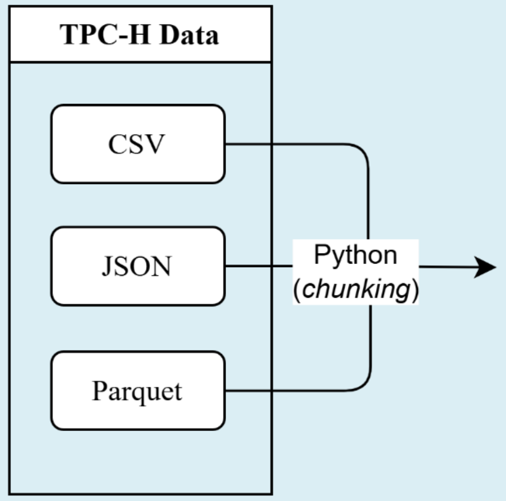

2

Load

Database

Tahap **pemuatan data** ke dalam sistem basis data PostgreSQL target.

Masih berupa data mentah

3

Transform

Melakukan **seluruh transformasi**, seperti:

- Penggabungan (*JOIN*)
- Agregasi
- Pemfilteran

Arsitektur Hibrida

1 *Extract*

Server

- **Membaca data** sumber TPC-H yang sudah dikonversi menjadi format CSV, JSON, dan Parquet
- Ekstraksi dilakukan menggunakan Python secara bertahap (*chunking*)

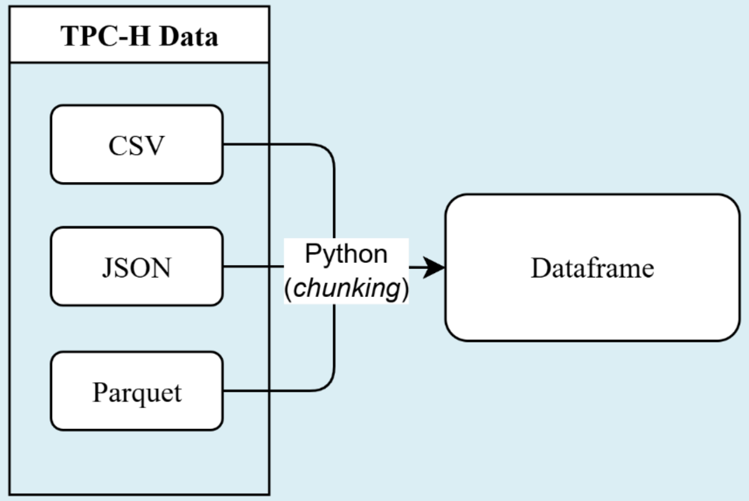

2 *Clean*

Tahap pembersihan data dan transformasi ringan

- Standarisasi nama kolom
- Penyesuaian tipe data
- Penghapusan duplikat

3 *Load*

Database

Tahap **pemuatan data** ke dalam sistem basis data PostgreSQL target.

4 *Transform*

Melakukan **transformasi berat**, seperti:

- Penggabungan (*JOIN*)
- Agregasi
- Pemfilteran

Tahap Pengujian

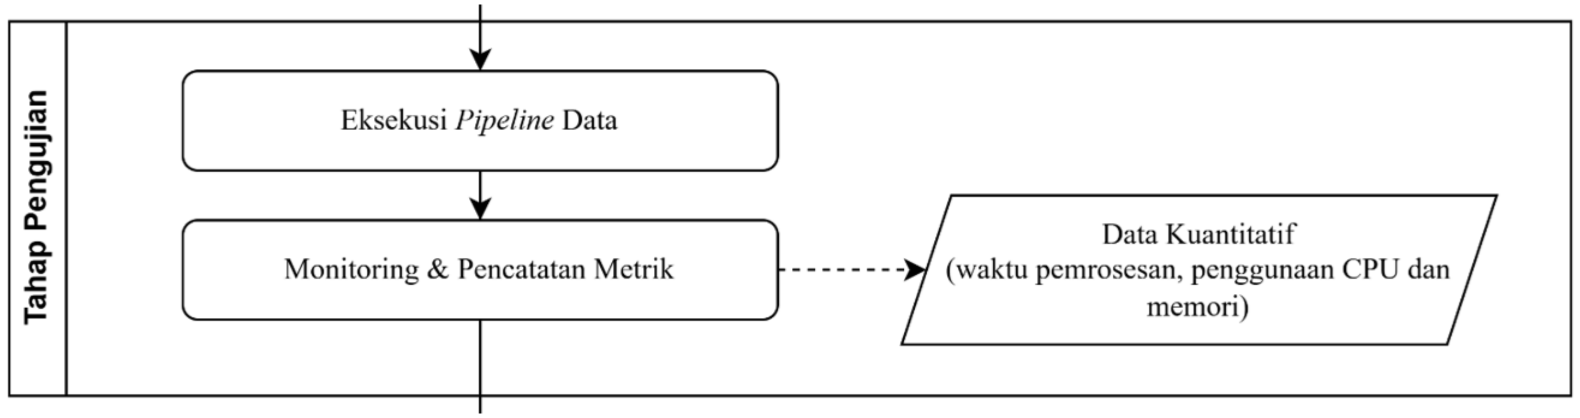

Eksekusi *Pipeline*

Arsitektur	Format Data
Extract, Transform, Load (ETL)	CSV
Extract, Load, Transform (ELT)	JSON
Hibrida	Parquet

Monitoring & Pencatatan Hasil

- **Waktu** Pemrosesan (detik)
- Pengujian **Efisiensi Sumber Daya**

Jadwal Pelaksanaan Tugas Akhir

No	Jenis Kegiatan	Bulan / Minggu																			
		Bulan ke-1				Bulan ke-2				Bulan ke-3				Bulan ke-4				Bulan ke-5			
		I	II	III	IV	I	II	III	IV	I	II	III	IV	I	II	III	IV	I	II	III	IV
1	Studi Literatur																				
2	Identifikasi Kebutuhan																				
3	Pengumpulan Data																				
4	Perancangan Arsitektur ETL																				
5	Perancangan Arsitektur ELT																				
6	Perancangan Arsitektur Hibrida																				
7	Tahap Pengujian																				
8	Tahap Analisis Hasil																				
9	Penyusunan Tugas Akhir																				

Sekian,

Terima Kasih